# ETL: введение

Лекция 1

# Знакомимся

Мышлянов Алексей Владимирович

Senior Data Scientist в МегаФон

Старший преподаватель на кафедре АСУ, НИТУ МИСиС

# Из чего будет состоять курс

~10 лекций и семинаров

Онлайн занятия

На выходе будем почти Data Engineer (в идеале)

Экзамен/зачет

Баллы в табличке, так что у большинства будет автомат (если будете делать, что требуется)

# Мотивация или Зачем вообще нужен ETL?

Данные в компаниях:

- Базы Данных
- API
- Логи
- Файлы
- итд.

Проблемы с такими данными:

- Разрозненность (все лежит в разных местах и в разных форматах. Data Fragmentation)
- Несогласованность (разные форматы данных, разные определения метрик, дубли, частота обновления разная)

**Без корректного pipeline данные бесполезны**

# Data Lake vs Data Swamp

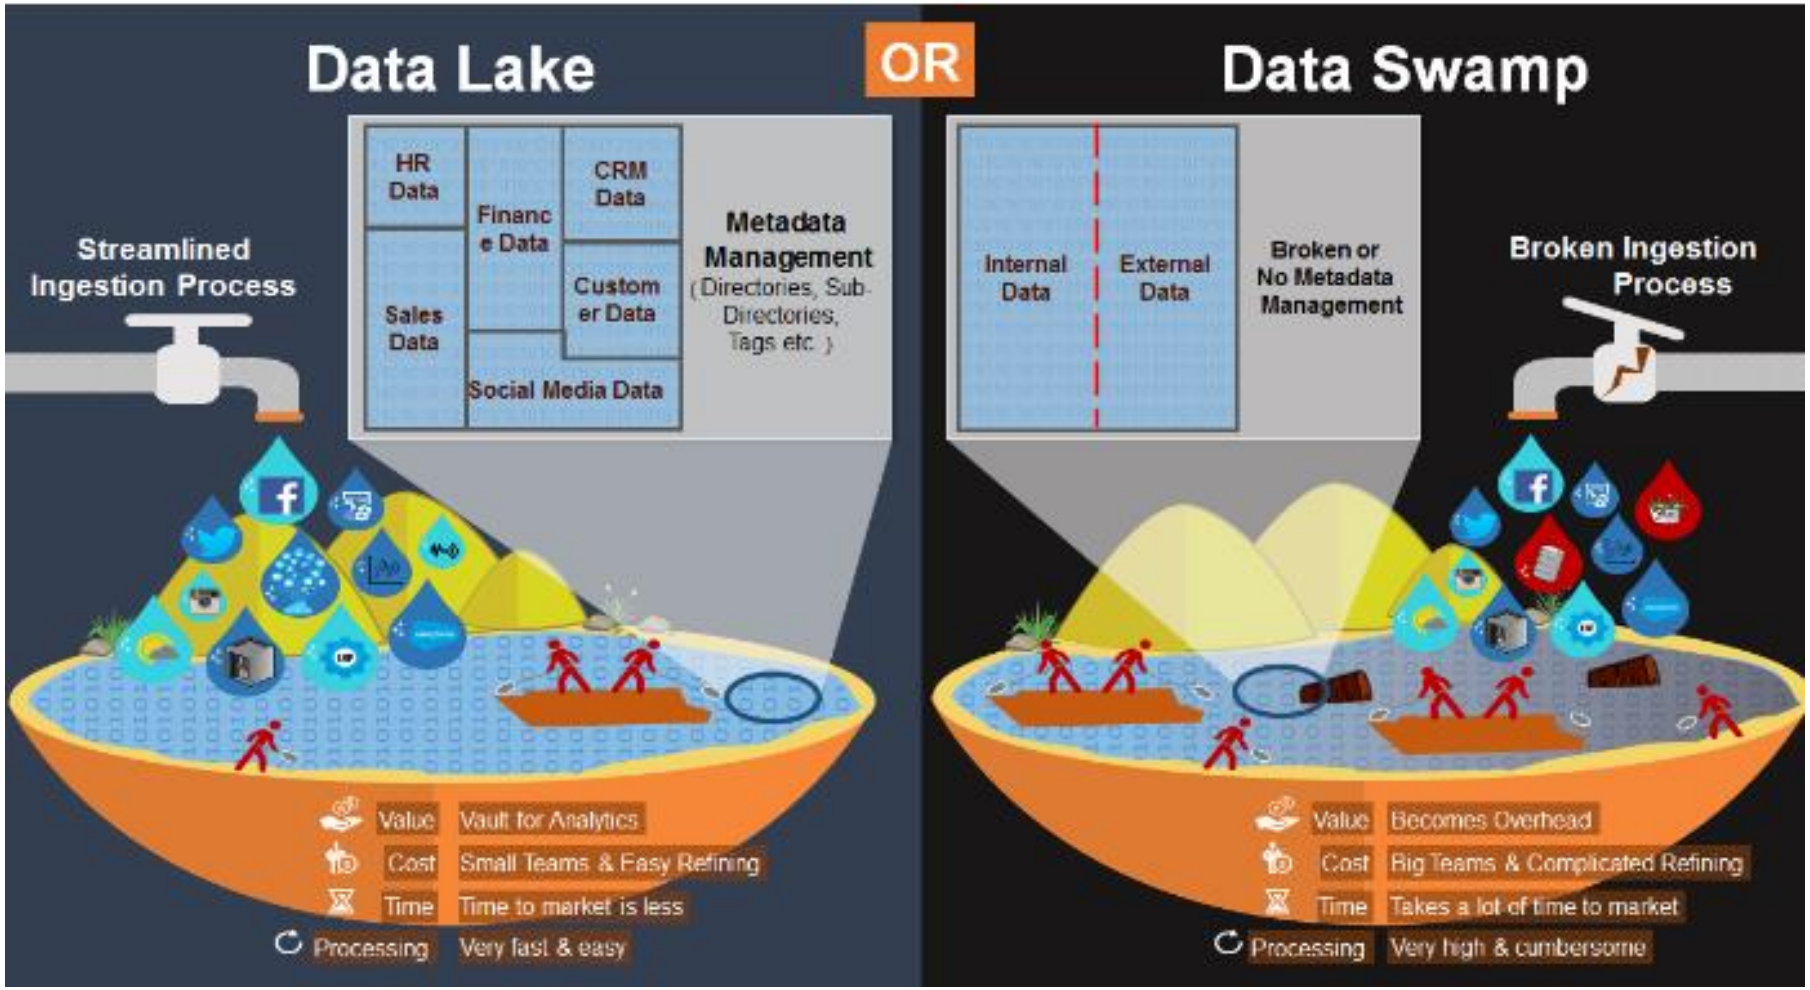

# Проблема «грязных» данных

Дубликаты

| user_id | email |
|---|---|
| 101 | alice@mail.com |
| 101 | alice@mail.com |
| 102 | bob@mail.com |

# Проблема «грязных» данных

Дубликаты

Пропуски

| order_id | user_id | amount |
|---|---|---|
| 1 | 101 | 100 |
| 2 | 102 | |
| 3 | 103 | 250 |

# Проблема «грязных» данных

Дубликаты

Пропуски

Разные форматы дат

| order_id | created_at |
|---|---|
| 1 | 2024-01-02 |
| 2 | 02.01.2024 |
| 3 | 01/02/24 |

# Проблема «грязных» данных

Дубликаты

Пропуски

Разные форматы дат

Несовпадающие ID

| user_id | name |
|---|---|
| 123 | Alice |

| client_id | country |
|---|---|
| 000123 | NL |

# Проблема «грязных» данных

Дубликаты

Пропуски

Разные форматы дат

Несовпадающие ID

Разные определения метрик

| order_id | amount |
|---|---|
| 1 | 100 |
| 2 | -500 |

# Что такое ETL?

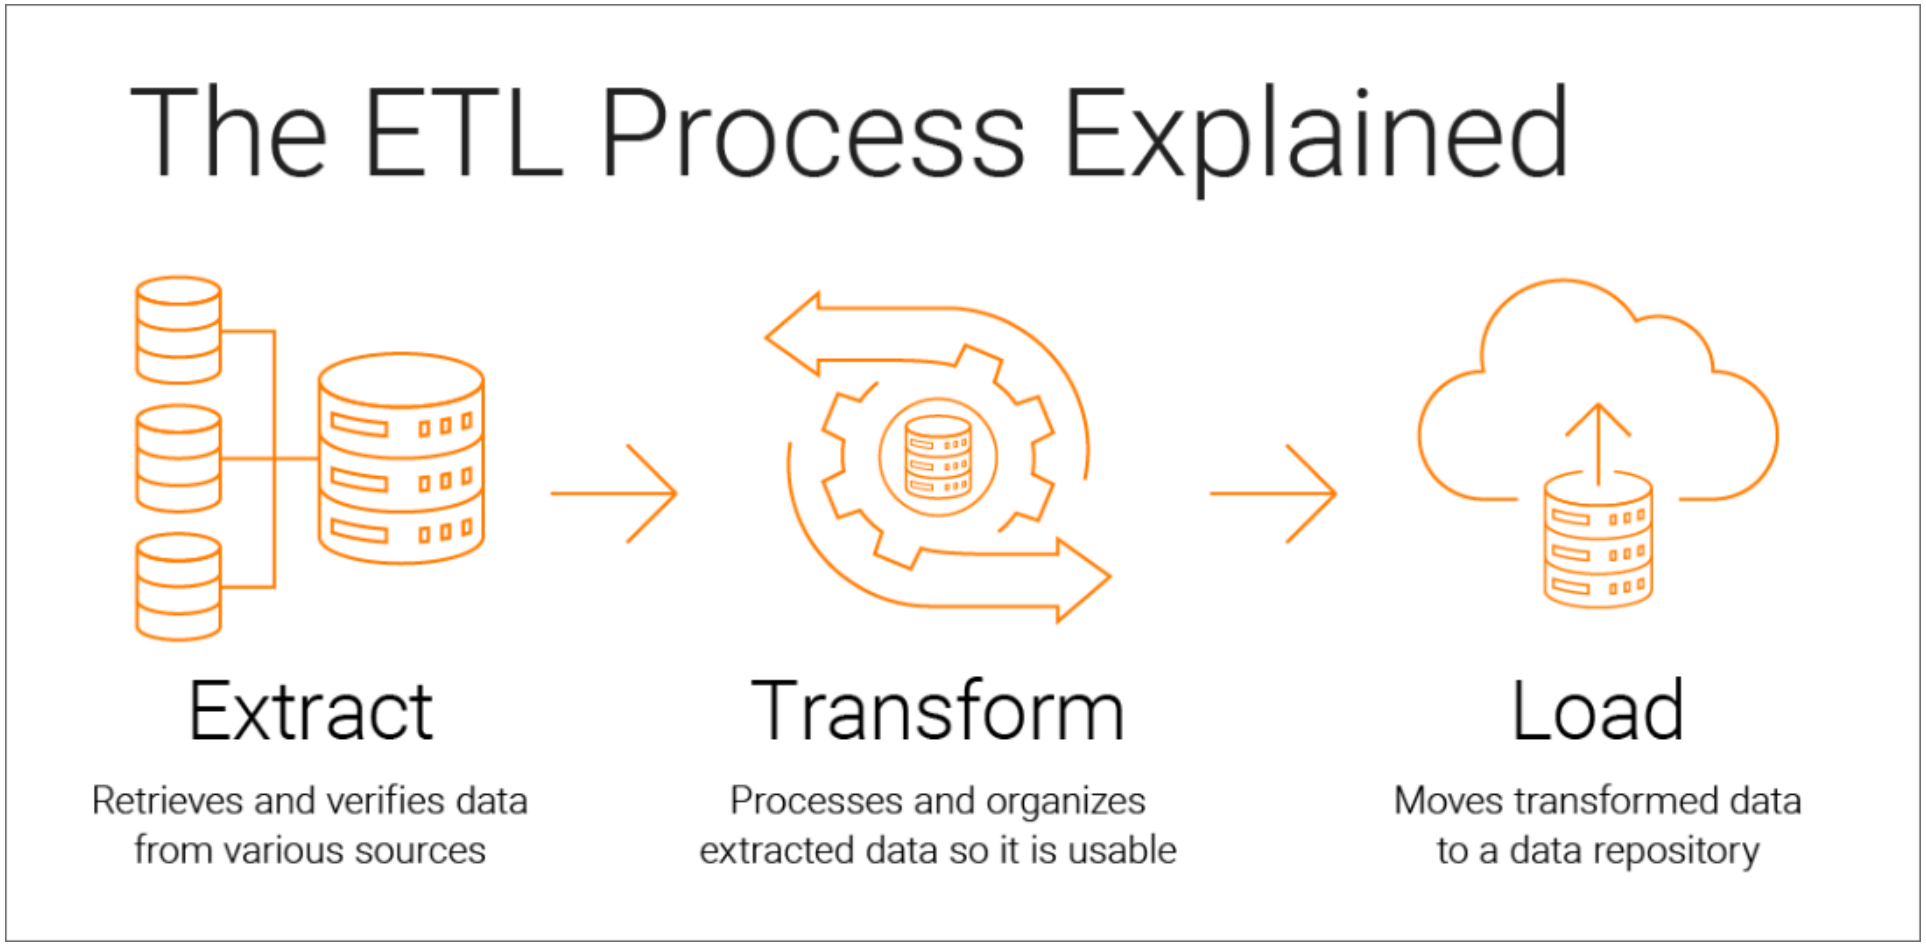


**ETL — это процесс, а не скрипт**

# ETL vs ELT

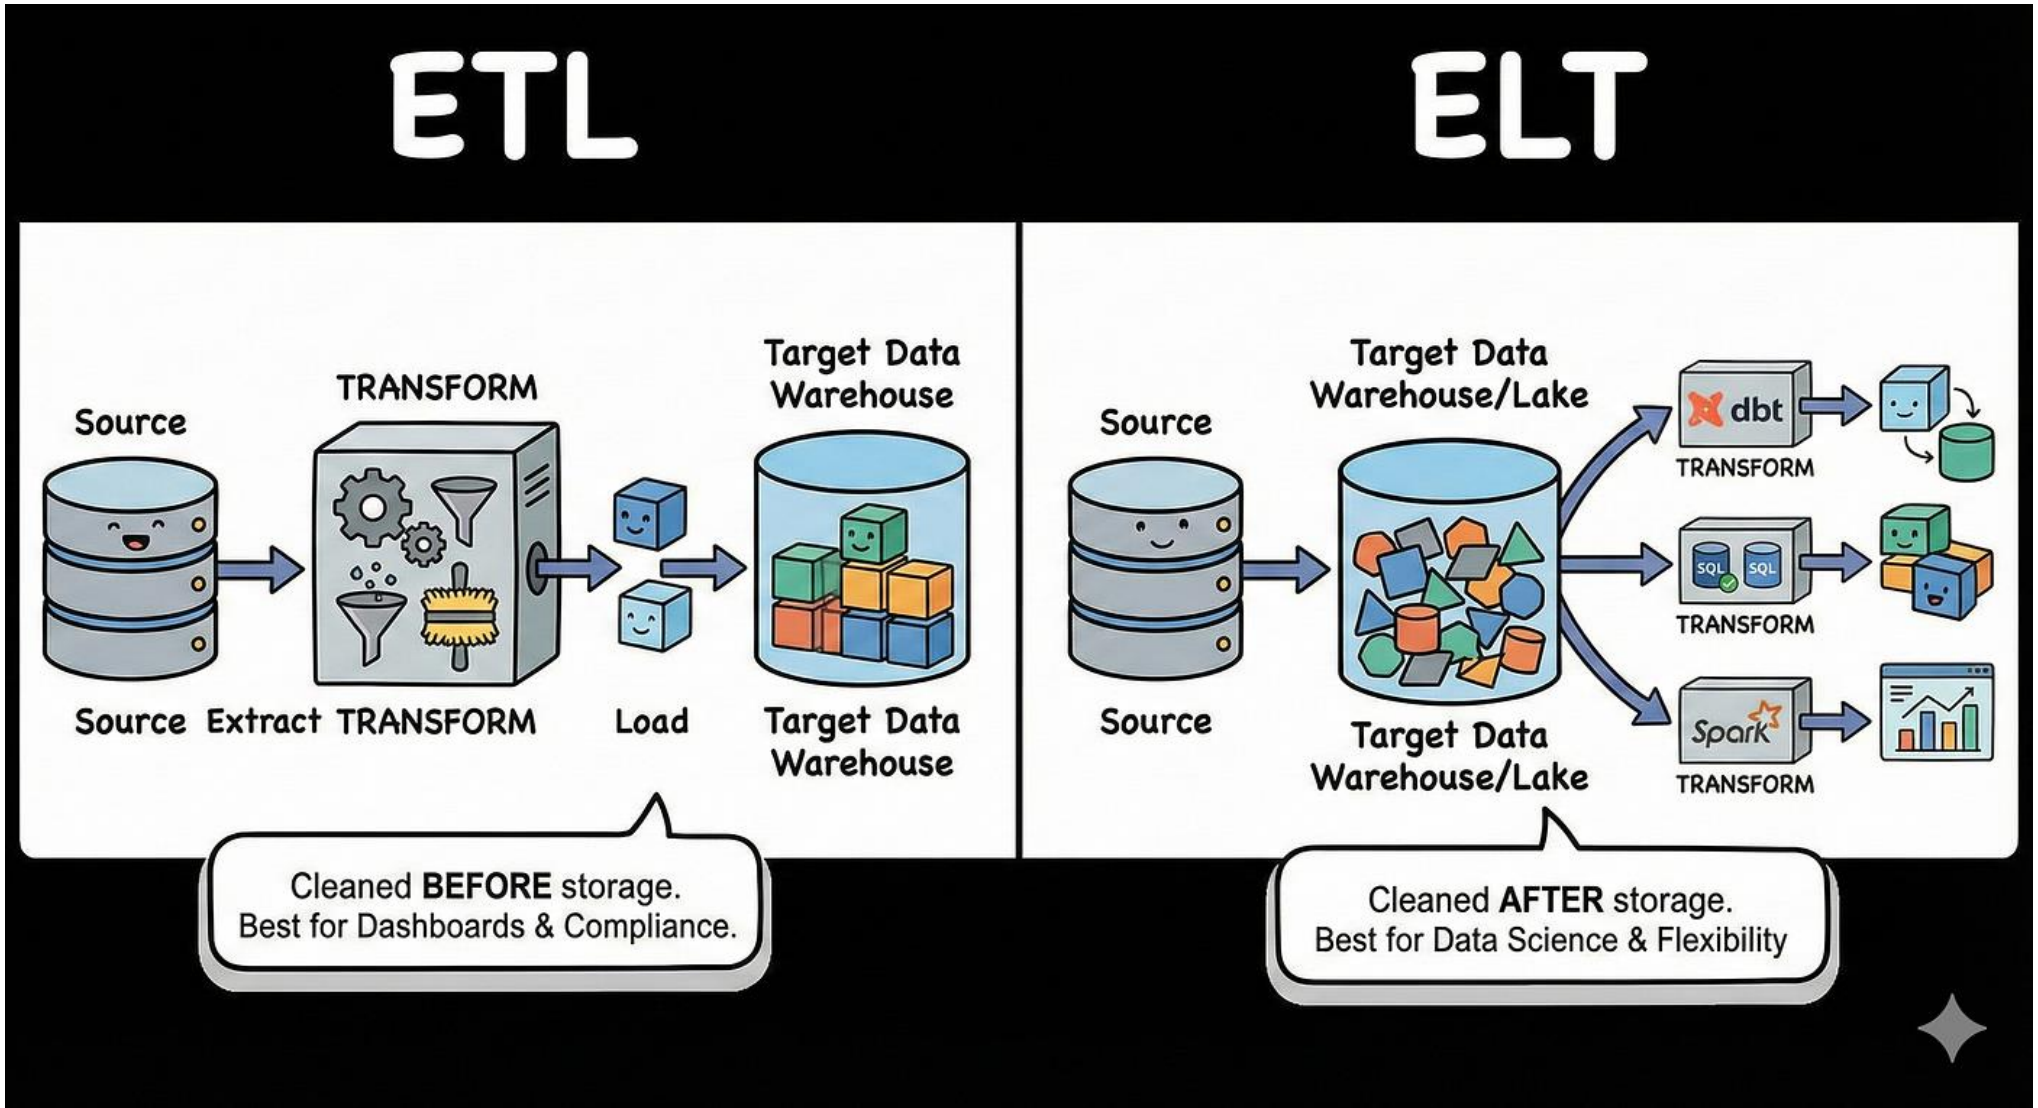
ETL
ELT
Source
TRANSFORM
Target Data Warehouse
Source Extract TRANSFORM
Load
Target Data Warehouse
Cleaned BEFORE storage.
Best for Dashboards & Compliance.
Source
Target Data Warehouse/Lake
dbt
TRANSFORM
SQL
SQL
TRANSFORM
Spark
TRANSFORM
Source
Target Data Warehouse/Lake
Cleaned AFTER storage.
Best for Data Science & Flexibility

# Современный Data Pipeline

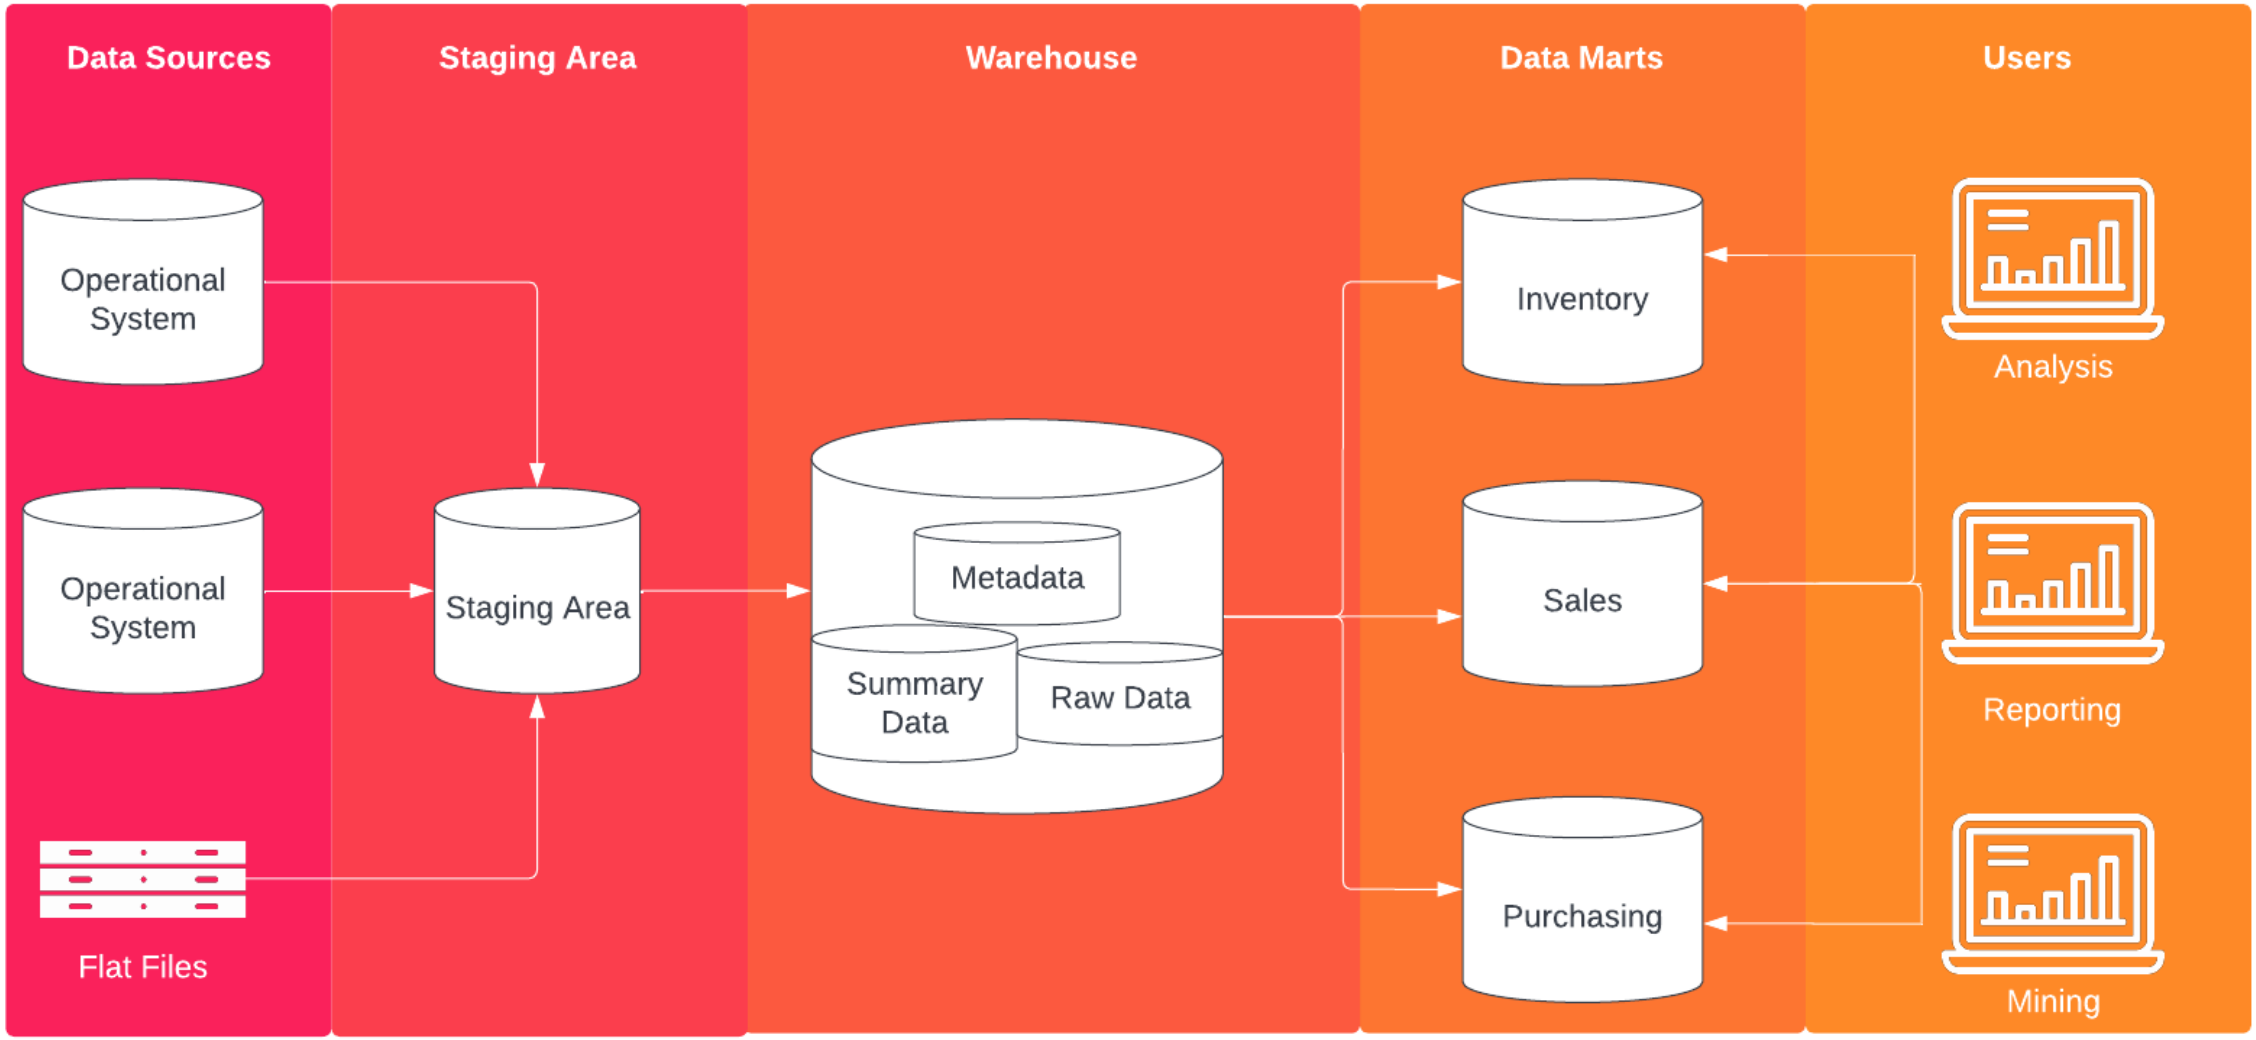

# Какие могут быть источники

- OLTP (транзакционные) базы
- API (json, xml)
- Файлы (csv, excel, json)
- События (json в kafka)

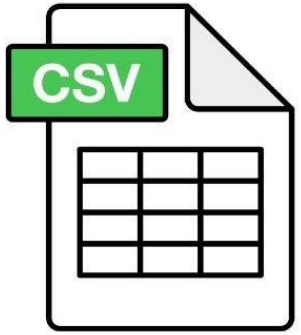

# Batch vs Streaming

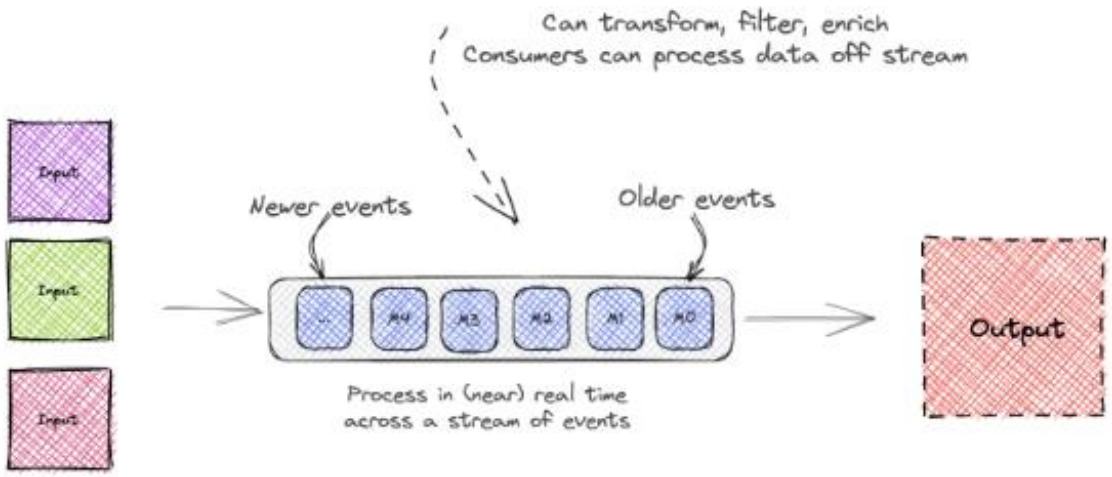


## Event Streams

Data processed as it arrives in (near) real-time.
Ideal for tasks that require real-time insights or immediate action.

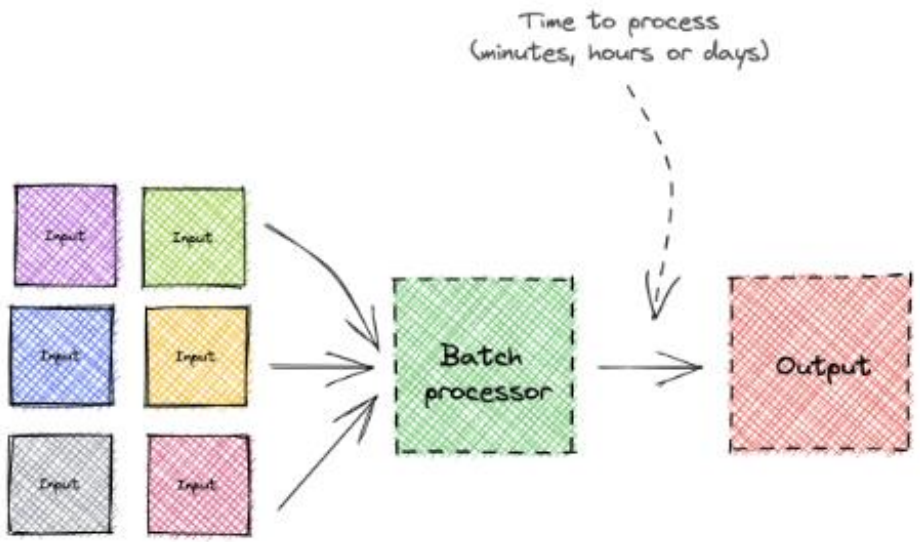


## Batch processing

Typically used for processing large amounts of data.
Ideal for tasks that do not require real-time processing.

# Кто такой Data Engineer?

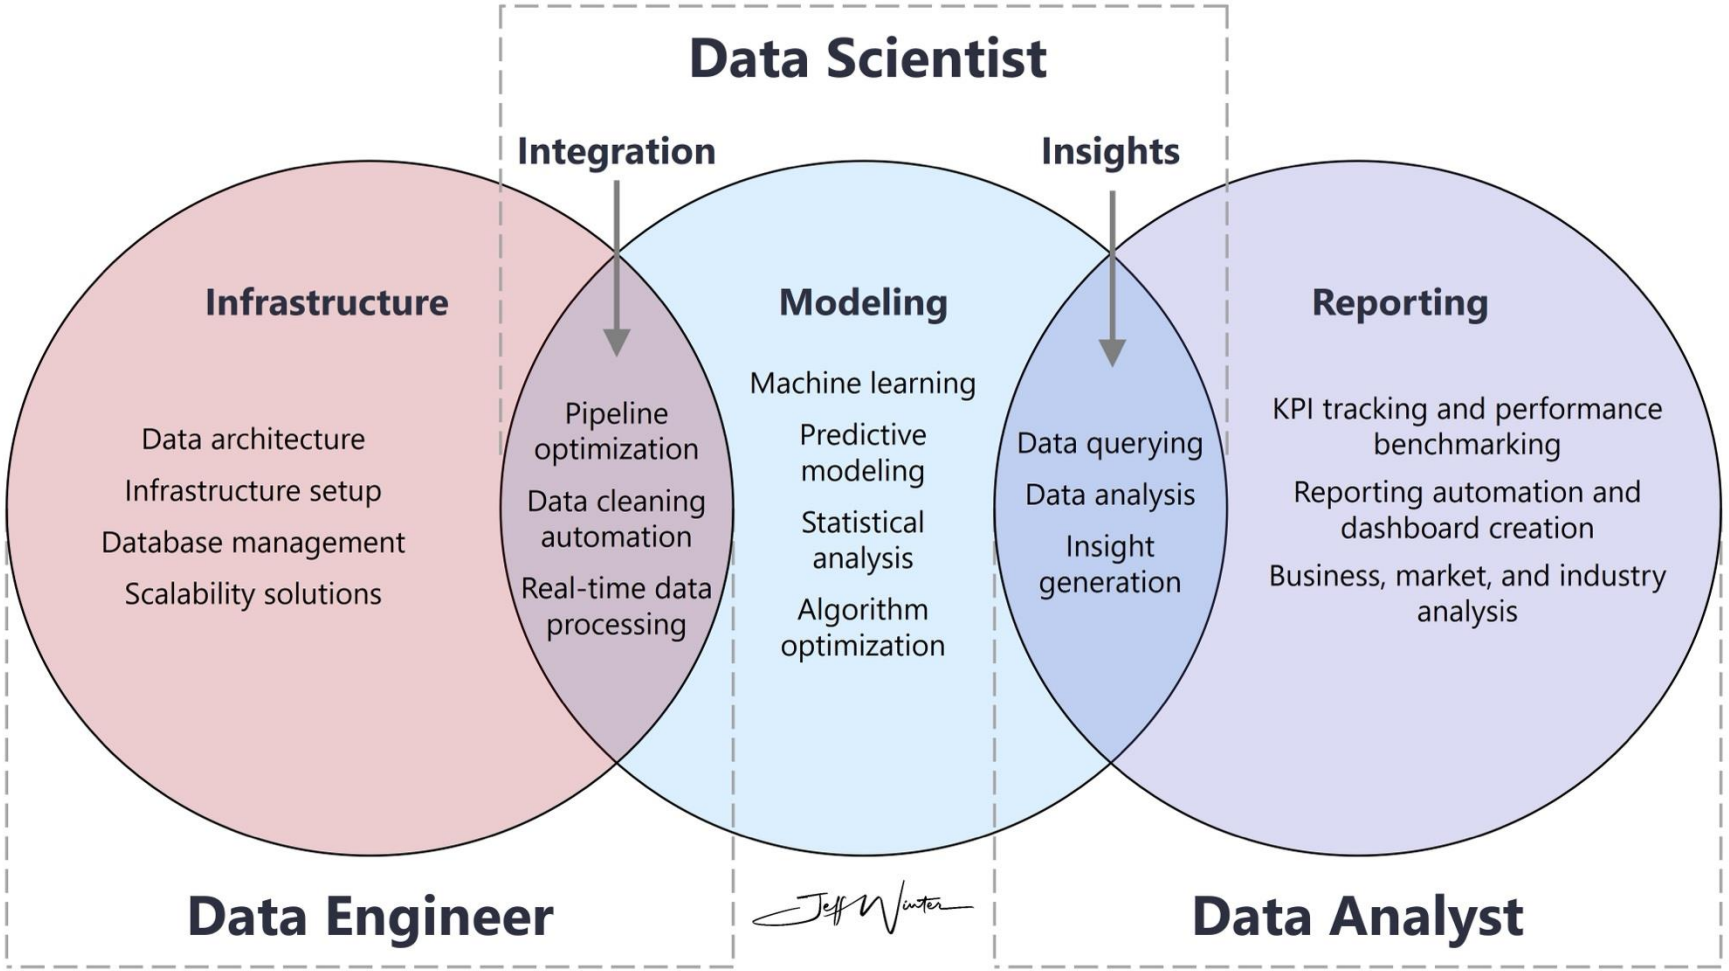


Adaptation of the data science diagram created by Kevin Schmidt in Towards Data Science, 2015

# Стек Data Engineer

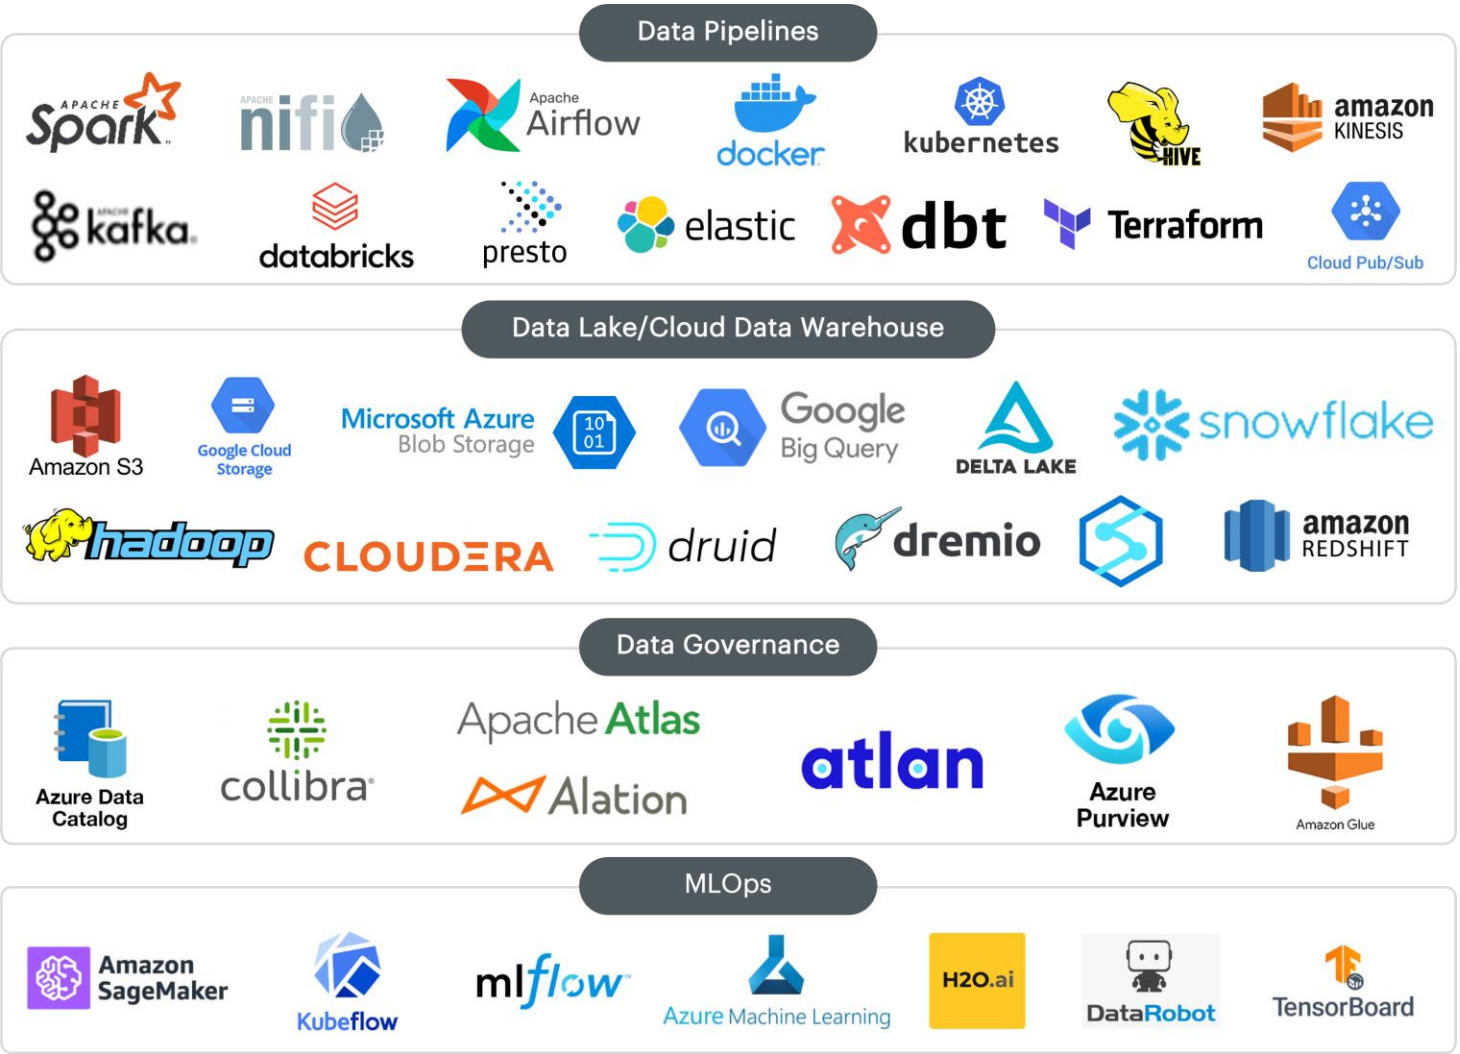

# Основные требования к ETL

**Надежность** – пайплайн стабильно работает и корректно обрабатывает ошибки

# Основные требования к ETL

**Надежность** – пайплайн стабильно работает и корректно обрабатывает ошибки

**Идемпотентность** – повторный запуск пайплайна не меняет результат

# Основные требования к ETL

**Надежность** – пайплайн стабильно работает и корректно обрабатывает ошибки

**Идемпотентность** – повторный запуск пайплайна не меняет результат

**Масштабируемость** – пайплайн способен работать при росте объема данных

# Основные требования к ETL

**Надежность** – пайплайн стабильно работает и корректно обрабатывает ошибки

**Идемпотентность** – повторный запуск пайплайна не меняет результат

**Масштабируемость** – пайплайн способен работать при росте объема данных

**Наблюдаемость** – возможность понимать, что происходит внутри пайплайн

# Основные требования к ETL

**Надежность** – пайплайн стабильно работает и корректно обрабатывает ошибки

**Идемпотентность** – повторный запуск пайплайна не меняет результат

**Масштабируемость** – пайплайн способен работать при росте объема данных

**Наблюдаемость** – возможность понимать, что происходит внутри пайплайна

**Документированность** – пайплайн понятен другим людям без чтения всего кода

# Что сделаем на этом курсе

- Построим полноценный ETL
- Сделаем инкрементальные загрузки
- Настроим оркестрацию
- Добавим проверки качества
- Подготовим mini-production pipeline

# Семинар сегодня

- Структура проекта
- Первый ETL-скрипт
- Логирование
- Разделение на raw и processed